

AUDITORÍA DE INTELIGENCIA ARTIFICIAL CLÍNICA

7 investigaciones independientes · 4 horas · enfoque LATAM · resultado reproducible

Objetivo

Convertir los siete ejes de ética, seguridad y validación de IA clínica en una experiencia práctica: cada estudiante/equipo investiga un problema clínico concreto, genera un análisis reproducible y produce un resultado que puede convertirse posteriormente en un protocolo, póster o manuscrito científico.

IMPORTANTE: el trabajo de 4 horas no garantiza publicación ni aceptación en una revista o conferencia Q1/Q2. El diseño está estructurado para dejar un piloto reproducible que pueda ampliarse con muestra suficiente, aprobación ética cuando corresponda, validación externa y análisis estadístico riguroso.

Pregunta guía

¿Qué evidencia necesitamos antes de permitir que una IA influya en una decisión clínica en nuestro contexto?

1. Arquitectura de las 4 horas

Tiempo	Bloque	Resultado
00–15 min	Elegir problema clínico	Pregunta de investigación
15–45	11.1 Bias	Matriz de perturbación
45–75	11.2 Fairness	Tabla/gráfico de brechas
75–105	11.3 Privacidad	Análisis privacidad–utilidad
105–135	11.4 Consentimiento	Aviso/consentimiento + prueba de comprensión
135–165	11.5 Explicabilidad	Predicción–explicación–concordancia
165–195	11.6 Seguridad	Registro de riesgos y fallos
195–230	11.7 Validación	Métricas + plan de validación externa
230–240	Pitch	Presentación de 60 segundos

Regla de oro: no se utilizan datos identificables de pacientes en notebooks públicos. Para el laboratorio se emplean datos sintéticos, desidentificados o datasets públicos apropiados.

11.1 · BIAS

¿Funciona igual en todos los subgrupos?

- Herramienta: Google Machine Learning Crash Course / Fairness.
- Construir dos casos clínicos idénticos y cambiar una sola característica sociodemográfica/contextual.
- Registrar clasificación, recomendación, confianza, derivación y pruebas adicionales.
- No declarar automáticamente 'sesgo': cuantificar qué cambió y discutir explicaciones alternativas.

Producto: matriz de perturbación sociodemográfica + gráfico de cambio de recomendación.

Pregunta de investigación: ¿qué variable controlada produce el mayor cambio en la recomendación de IA?

11.2 · FAIRNESS

¿Algún grupo recibe peor sensibilidad/especificidad?

- Herramienta: Fairlearn MetricFrame.
- Calcular sensibilidad, especificidad, FPR, FNR y, cuando sea apropiado, PPV/NPV por subgrupo.
- Comparar magnitudes y tamaños de muestra.
- Reportar diferencias como resultados cuantitativos; no confundir una diferencia observada con una explicación causal.

Producto: Fairness Gap Dashboard + tabla por subgrupo.

Pregunta de investigación: ¿el rendimiento global oculta diferencias clínicamente relevantes entre grupos?

11.3 · PRIVACIDAD

¿Cómo se protegen imágenes, EHR y datos identificables?

- Herramienta: ARX para datos tabulares sintéticos/desidentificados.
- Clasificar identificadores directos, cuasi-identificadores y atributos sensibles.
- Aplicar anonimización y observar riesgo de reidentificación e información perdida.
- Construir una curva privacidad–utilidad.

Producto: Privacy–Utility Curve + inventario de variables sensibles.

Pregunta de investigación: ¿cuál es el nivel mínimo de transformación que reduce riesgo sin destruir utilidad clínica?

11.4 · CONSENTIMIENTO

¿El paciente sabe que IA participa en su atención?

- Actividad: diseño de información al paciente, no programación.
- Crear dos versiones: técnica y lenguaje claro.
- Explicar propósito, datos utilizados, papel de la IA, revisión humana, errores, privacidad y posibilidad de preguntas.
- Hacer una microprueba de comprensión entre compañeros; no presentar esto como validación clínica de pacientes.

Producto: AI Patient Information Sheet + comparación de comprensión.

Pregunta de investigación: ¿una explicación simplificada mejora la comprensión del papel de la IA?

11.5 · EXPLICABILIDAD

¿Podemos entender por qué el modelo marcó riesgo?

- Herramienta: SHAP y notebooks de ejemplos.
- Ejecutar predicción → explicación → interpretación clínica.
- Identificar las variables/regiones que más contribuyen.
- Comparar una explicación clínicamente plausible con una inesperada.
- Recordar: una explicación de modelo no demuestra causalidad.

Producto: Prediction–Explanation–Clinical Concordance figure.

Pregunta de investigación: ¿la concordancia entre explicación del modelo y criterio clínico puede detectar predicciones potencialmente problemáticas?

11.6 · SEGURIDAD

¿Qué ocurre cuando la IA se equivoca?

- Marco: NIST AI RMF: Govern, Map, Measure, Manage.
- Introducir fallos: falso negativo, falso positivo, datos faltantes, valores anómalos, cambio de población o fallo del sistema.
- Para cada fallo documentar consecuencia clínica, detección, mitigación y acción humana.
- Diseñar un 'AI Failure Day' como prueba controlada.

Producto: Failure Mode → Clinical Harm → Detection → Mitigation map.

Pregunta de investigación: ¿qué fallos clínicamente importantes no son visibles mediante las métricas habituales?

11.7 · VALIDACIÓN CLÍNICA

¿Funciona fuera del contexto donde fue desarrollado?

- Herramienta: Google Colab + MONAI/PyTorch o notebook clínico simplificado.
- Separar entrenamiento, validación y test.
- Calcular matriz de confusión, sensibilidad, especificidad y AUC cuando corresponda.
- Analizar errores y subgrupos.
- Diseñar una cohorte externa o una prueba de generalización usando otro dataset/contexto disponible.

Producto: Validation Card + comparación interna/externa.

Pregunta de investigación: ¿qué evidencia adicional necesitamos antes de transferir el modelo a otro hospital/población?

2. Asignación de problemas clínicos LATAM

Para evitar siete trabajos idénticos, cada estudiante/equipo recibe un contexto diferente. El mismo método de auditoría se conserva, pero cambia la pregunta clínica.

Área	Ejemplo de problema
Oftalmología	Tamizaje de retinopatía diabética
Obstetricia	Predicción/priorización de riesgo materno
Urgencias	Deterioro clínico
Radiología	Triage de radiografías de tórax
Cardiología	Riesgo cardiovascular
Salud mental	Clasificación/triage asistido por IA
Farmacia	Recomendación/seguridad de medicación
Fisioterapia	Predicción de recuperación funcional
Enfermería	Riesgo de caídas o deterioro
Rehabilitación	Monitoreo de progreso
Pediatría	Riesgo respiratorio
Salud pública	Tamizaje de tuberculosis

Los temas pueden adaptarse al servicio clínico local, pero no deben utilizar datos personales reales durante el laboratorio.

3. Producto final de cada equipo

Cada equipo entrega cinco piezas. Juntas forman una mini-investigación reproducible.

Entrega	Contenido mínimo
1. Pregunta	Una pregunta clínica específica y medible.
2. Análisis reproducible	Notebook/hoja de cálculo + dataset o fuente + parámetros.
3. Figura original	Un gráfico generado por el equipo, no una captura sin análisis.
4. Flujo clínico	IA → profesional → paciente → acción / escalamiento.
5. Mini-manuscrito	Título, background, objetivo, métodos, resultados, implicación, limitaciones y siguiente validación.

Formato de mini-manuscrito

- Título** · específico y verificable.
- Background** · problema clínico y por qué importa.
- Objective** · una pregunta concreta.
- Methods** · datos, población, herramienta y métricas.
- Results** · números y figura principal.
- Clinical implication** · qué significa para el flujo asistencial.
- Limitations** · tamaño, representatividad, datos y diseño.
- Next validation** · qué experimento externo/prospectivo hace falta.

Para trabajos de modelos predictivos, TRIPOD+AI puede utilizarse como guía de reporte; para intervenciones clínicas con IA, CONSORT-AI es una referencia adicional. Estas guías mejoran la transparencia del reporte, pero no convierten automáticamente un trabajo corto de clase en un estudio publicable.

4. Pitch científico de 60 segundos

Cada equipo dispone de 60 segundos. Debe responder exactamente cinco preguntas:

1. ¿Cuál es el problema clínico?
2. ¿Qué hicimos con la IA?
3. ¿Cuál fue el resultado principal?
4. ¿Cuál es el principal riesgo o limitación?
5. ¿Qué validación necesitamos después?

Plantilla

“Investigamos _____ en _____. Utilizamos _____ para evaluar _____. Encontramos _____. El principal riesgo/limitación fue _____. Antes de utilizarlo clínicamente, proponemos _____.”

Criterio científico

Los estudiantes deben separar claramente: resultado observado, interpretación y afirmación que todavía no puede hacerse.

5. Cómo convertir el piloto en investigación

El producto de cuatro horas debe considerarse un **piloto reproducible**. Para convertirse en un estudio sometible a una conferencia o revista, el equipo deberá ampliar posteriormente:

- muestra y potencia estadística cuando corresponda;
- definición prospectiva del protocolo;
- aprobación ética/consentimiento cuando se utilicen personas o datos identificables;
- validación externa;
- análisis de subgrupos preespecificados;
- intervalos de confianza y análisis estadístico apropiado;
- documentación completa del dataset y del pipeline;
- reproducibilidad del código;
- evaluación de utilidad clínica y seguridad;
- reporte conforme a la guía apropiada.

No se debe afirmar que un modelo es seguro, justo o clínicamente eficaz solamente porque haya funcionado en un ejercicio de cuatro horas.

Referencias prácticas

WHO — Ethics and Governance of Artificial Intelligence for Health.

NIST — AI Risk Management Framework / Playbook.

Fairlearn — Fairness Assessment / MetricFrame.

ARX — Data Anonymization Tool.

SHAP — Explainable AI examples.

Project MONAI — Healthcare Imaging tutorials.

TRIPOD+AI — Reporting guideline for clinical prediction models.

CONSORT-AI — Reporting guideline for clinical trials involving AI.

Fuentes web: WHO, NIST, Fairlearn, ARX, SHAP, Project MONAI, BMJ/TRIPOD+AI y CONSORT-AI. Las herramientas deben utilizarse según sus versiones y documentación vigentes.